线性回归

机器学习基础模型

刘臆杨

今天我们学什么？

1. 引入
2. 线性回归模型
3. 最小二乘法推导过程（选学）
4. 动手体验小程序！
5. 思考与讨论

📌 **核心目标**

理解线性回归的思想，

亲手用最小二乘法找到最优直线！

引入

一个真实的问题：电动汽车耗电量

🚗 **场景**

自动驾驶电动汽车的**耗电量**与**行驶路程**之间存在一定关联——路程越长，耗电越高。

但并不是严格的倍数关系：同样行驶 60 km，不同路况、坡度下耗电量会有差异。

我们的问题：

绿色的点是真实环境下采样得到，能否通过这些点来预测电动汽车行驶至 90km 处时的耗电量？

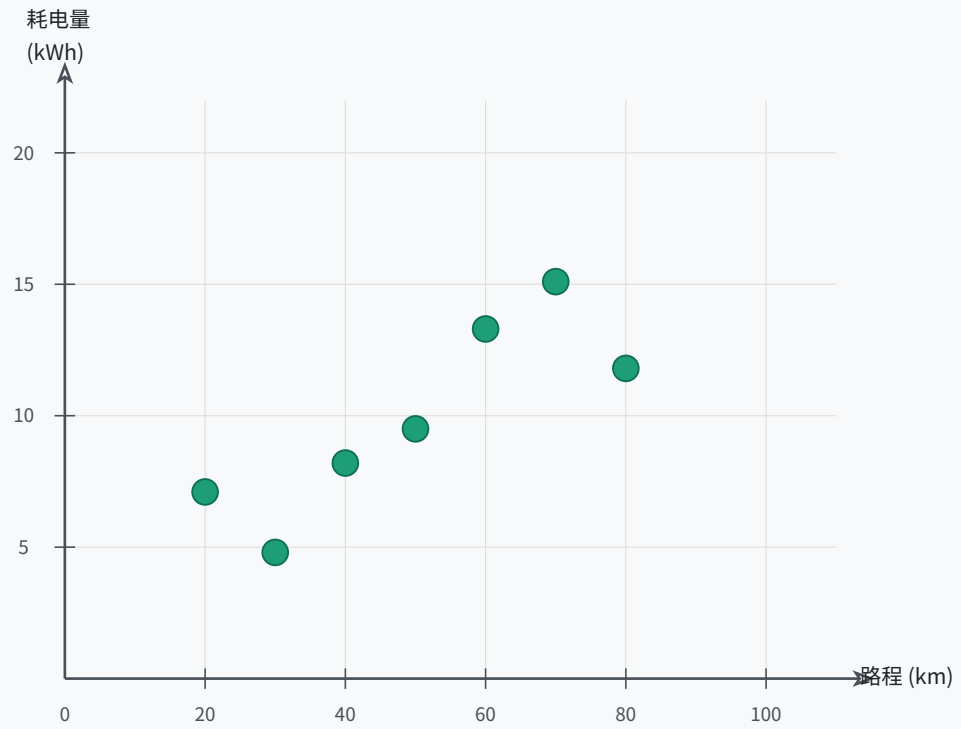

一个真实的问题：电动汽车耗电量

我们假设：

电动汽车路程与耗电量的关系可以用一次函数（一条直线）+ 无法预测的随机噪声来描述，形如：

$$f(x) = kx + b + \varepsilon$$

这样的自变量 - 因变量关系我们称为**线性关系**。

我们需要让机器通过学习，总结出预测最为准确的一组函数的参数(k, b)。

以得出**最优线性关系**为目标的机器学习问题我们称为**线性回归问题**。

数据	模型	输出
所有已知点	某个满足我们需求的一次函数	用训练好的模型代入$x = 90$后的值

线性回归模型

什么叫“最优”线性关系?

平面上存在**无数条**直线，
没有任何一条能经过所有数据点。

对于每一条直线，每个数据点都会产生一个误差 e_i = 真实值 y_i - 预测值 $f(x_i)$：

$$e_i = y_i - f(x_i) = y_i - (kx_i + b)$$

我们把**所有数据点误差**（的平方）加起来，作为衡量直线好坏的标准。

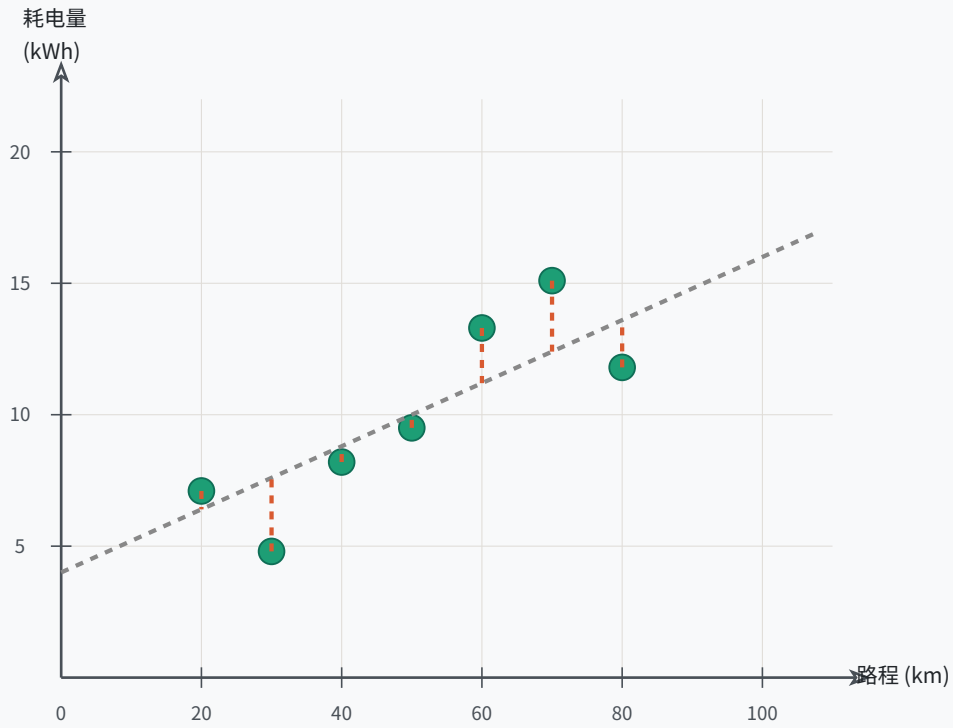

什么叫“最优”线性关系?

? 为什么要平方?

- 误差可正可负，直接相加会相互抵消，平方后**所有误差都为非负数**
- 平方还会**放大大误差**，让优化更敏感
- 平方函数很平滑（处处可导）

🎯 损失函数 — 误差平方和 (SSE)

$$\mathrm{SSE} = \sum_i (e_i)^2 = \sum_i (y_i - (kx_i + b))^2$$

最优直线 → 使 SSE 最小的直线

损失：当前模型效果与“最优”效果的差距。

损失函数：模型参数（此处为 k 和 b）与损失的关系。

如何找到最优直线?

🎯 损失函数 — 误差平方和 (SSE)

$$\mathrm{SSE} = \sum_i \left(y_i - (kx_i + b)\right)^2$$

如何找到一条使损失（SSE）比较小的直线?

如何找到最优直线?

🎯 损失函数 — 误差平方和 (SSE)

$$\mathrm{SSE} = \sum_i \left(y_i - (kx_i + b)\right)^2$$

如何找到一条使损失（SSE）比较小的直线?

1. 尝试每个可能的 k 和 b （随机搜索）
2. 通过数学推导求直接求出损失函数的全局最小值 （最小二乘法）
3. 取一对随机的 k 和 b ，计算出损失函数此时的梯度值，用参数减去梯度值，然后重复此过程，直到损失不再下降。（梯度下降法）

最小二乘法推导过程（选学）

最小二乘法推导过程（选学）

一元线性回归问题的损失函数本质上是一个二元二次函数，形如：

$$f(x, y) = ax^2 + bxy + cy^2 + dx + ey + f$$

由 Hessian 判别法可知当 $\Delta > 0$ 且 $a > 0$ 时，函数有且仅有一个极小值点。

又因为此时该函数为严格凸函数，所以该极小值点即为最小值点。

最小二乘法推导过程（选学）

对 SSE 分别对 k、b 求偏导并令其为 0：

$$\frac{\partial}{\partial k}\sum_i (y_i - (kx_i + b))^2 = 0$$

$$\frac{\partial}{\partial b}\sum_i (y_i - (kx_i + b))^2 = 0$$

对二次函数求极值，令导数为 0，即可找到最小值所对应的参数。
当方程组的系数向量**线性无关**时，存在唯一的解析解。

最小二乘法推导过程（选学）

联立求解，得到 k 和 b 的**精确计算公式**：

$$k = \frac{N\sum x_i y_i - \sum x_i \cdot \sum y_i}{N\sum x_i^2 - \left(\sum x_i\right)^2}$$

$$b = \frac{\sum y_i - k\sum x_i}{N}$$

N 为数据点总数

动手体验！🧪

小程序使用说明

双击打开今天的课程小程序：`linear_regression_interactive.html`

1. **输入数据**：鼠标指针在坐标系中左键点出一些数据点
2. **观察回归直线**：蓝色直线由最小二乘法自动计算，记录方程中的 k 和 b
3. **显示误差线**：点击「显示误差线」，观察每个点到直线的误差及对应的正方形面积
4. **手动探索**：切换到「手动探索」标签，拖动滑块调整直线，尝试让你的 SSE 接近最优值

任务卡：亲手验证最小二乘法

📋 探索任务

1. **记录最优参数**：载入数据后，写下 k、b 和最优 SSE
2. **手动挑战**：切换到「手动探索」，尝试将你的 SSE 调到最优值的 **1.5 倍以内**
3. **加入新数据**：在画布上再单击添加 3 个点，观察回归直线如何变化
4. **思考异常点**：尝试加入一个偏离很远的点（如路程 50，耗电 20），观察直线变

> 提示：SSE 越小，直线越“贴近”数据点。最优 SSE 由公式保证，手动调整无法超越它。

思考与讨论 💬

深入思考

问题 1

如果我们加入一个路程很短但耗电量异常高的数据点，
回归直线会怎样变化？这说明了什么？

问题 2

线性回归假设路程和耗电量的关系是**线性的**。
现实中这个假设一定成立吗？如果不成立，
会产生什么问题？

线性回归是机器学习中**最简单**的模型，
但它的思想——“用数据找规律，最小化损失”——
贯穿了几乎所有复杂的机器学习算法。

本课小结

今天我们学到了什么?

知识点 1 **线性回归**分析自变量 x 与因变量 y 之间的线性关系，用 $f(x) = kx + b$ 表示

知识点 2 **误差平方和（SSE）**是衡量直线好坏的损失函数，最优直线使 SSE 最小

知识点 3 **最小二乘法**是求解线性回归问题的一种方法，可直接计算出唯一的最优 k 和 b

我们还 **亲手体验**了线性回归小程序，直观感受最小二乘法求解最优直线的过程!

📎 课后延伸

思考：如果自变量有两个（路程 + 坡度），还能用直线描述吗?

如果在其他机器学习问题中，损失函数没有办法求出最小值，该怎么办?

课后小测